Cahier des charges : Projet météo MLOps

1. Introduction :

Le projet météo est un projet dans le cadre de la formation MLOps proposé par l'organisme Datascientest. Nous sommes un groupe de 3 personnes : Grégory Herré, Pascal Dkengne Sielenou. Nous sommes accompagnés par un tuteur de projet : Sébastien.

Ce projet constitue un module de notre formation et a pour objectif de d'évaluer notre capacité à implémenter et à automatiser le lancement de toutes les étapes associées au MLOps.

2. Définir le projet

Nous avons décidé de partir sur un projet qui a pour objectif de déterminer la météo afin d'aider les aéroports. Nous allons récupérer un fichier csv qui nous donne un certain nombre de variables ainsi qu'une variable que nous allons prédire. Cette variable que nous allons prédire c'est la Pluie « oui ou non ».

1. La collecte des données

Nous allons utiliser une base sql pour collecter toutes les données. Nous allons également utiliser du web scrapping pour pouvoir avoir des données quotidiennement et ainsi pouvoir re-entrainer le modèle avec des données plus récentes.

Nous allons également rajouter une base de données que nous avons trouvé, avec tous les vols prévus ainsi que le nom de la compagnie. Cela va nous permettre d'identifier les compagnies qui ont des vols prévu lorsqu'une météo est jugé trop risqué.

Pour respecter les normes RGPD et ne pas prendre de risque nous allons mettre en place régulièrement une suppression des données dans notre base sql.

2. Automatisation du modèle

Afin de rendre ce projet accessible sur n'importe quel environnement de travail, nous allons utiliser un procédé appris lors de la formation. Pour utiliser nos modèles de machine learning nous allons utiliser docker. Pour les pipelines CI/CD nous allons utiliser git / github. Nous allons également faire des tests unitaires afin de vérifier que les données qui rentrent tous les jours respectent un certain nombre de règle.

3. Choix du modèle

Nous avons décidé d'utiliser un modèle de prédiction de classification. Afin d'aider au mieux et de façon très rapide les aéroports à prendre des décisions rapides. Afin de définir à quel seuil nous mettons la différence entre oui et non, nous allons définir plusieurs tests.

4. Définir l’API

Pour la création de l’API, nous avons décidé d’utiliser FastAPI afin de mettre en pratique ce que nous avons vu en cours. Les données seront protégées il faudra entrer un identifiant et un mot de passe communiqué à chaque aéroport. Pour ce projet nous mettrons en identifiant « aeroport » et en mot de passe « toto_australie »

En entrée dans l’API il faudra renseigner sa ville ainsi que la date souhaitée. En sortie il y aura deux phrases possibles : « le 14/09 aucune difficulté météorologique prévu » ou « Attention le 14/09 une fermeture de l’aéroport est à étudier »